

---

# Sistem Klasifikasi Tipe Kendaraan Transportasi dengan Metode SVM Berbasis Pengolahan Citra

**Fadhil Muhamad Pratama\*<sup>1</sup>, Leonardus Adi Widjayanto<sup>2</sup>, Luthfi Fauzi<sup>3</sup>**

<sup>1,2</sup>Telkom University; address, Jl. Telekomunikasi No. 1 Terusan Buahbatu

<sup>3</sup>Program Studi S1 Informatika, FIF Telkom, Bandung

[Fpratama@student.telkomuniversity.ac.id](mailto:Fpratama@student.telkomuniversity.ac.id), [Leonardusadi16@telkomuniversity.ac.id](mailto:Leonardusadi16@telkomuniversity.ac.id),

[Luthfafi@student.telkomuniversity.ac.id](mailto:Luthfafi@student.telkomuniversity.ac.id)

## **Abstrak**

Sistem klasifikasi tipe kendaraan transportasi menjadi semakin penting dalam pengelolaan lalu lintas dan peningkatan keamanan. Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi kendaraan menggunakan metode Support Vector Machine (SVM) berbasis pengolahan citra digital. Penelitian ini dilatarbelakangi oleh kebutuhan untuk meningkatkan efisiensi dan akurasi dalam identifikasi kendaraan di area publik. Proses pengembangan dimulai dengan pengambilan citra kendaraan dari berbagai sudut, diikuti dengan ekstraksi fitur menggunakan teknik Histogram of Oriented Gradients (HOG) untuk mendeteksi bentuk dan kontur kendaraan. Data yang telah diekstraksi kemudian dilatih menggunakan algoritma SVM untuk mengklasifikasikan tipe kendaraan, seperti mobil, sepeda motor, dan truk. Hasil pengujian menunjukkan bahwa sistem yang dikembangkan mampu mencapai akurasi keseluruhan sebesar 70% dalam mengidentifikasi berbagai jenis kendaraan. Temuan ini menggarisbawahi potensi metode SVM dalam aplikasi pengolahan citra untuk klasifikasi kendaraan, meskipun terdapat ruang untuk perbaikan, terutama pada tipe kendaraan dengan karakteristik visual yang kompleks. Penelitian ini diharapkan dapat memberikan kontribusi signifikan terhadap pengembangan sistem manajemen lalu lintas yang lebih efisien serta peningkatan keamanan publik melalui teknologi pemantauan yang cerdas.

**Kata kunci** Klasifikasi Kendaraan, Support Vector Machine (SVM), Pengolahan Citra

## **Abstract**

The classification system for transportation vehicle types is becoming increasingly important in traffic management and improving security. This study aims to develop a vehicle classification system using the Support Vector Machine (SVM) method based on digital image processing. This research is motivated by the need to improve efficiency and accuracy in vehicle identification in public areas. The development process begins with capturing vehicle images from various angles, followed by feature extraction using the Histogram of Oriented Gradients (HOG) technique to detect the shapes and contours of vehicles. The extracted data is then trained using the SVM algorithm to classify vehicle types, such as cars, motorcycles, and trucks. The test results indicate that the developed system achieves an overall accuracy of 70% in identifying various vehicle types. These findings highlight the potential of the SVM method in image processing applications for vehicle classification, although there is room for improvement, particularly for vehicle types with complex visual characteristics. This study is expected to contribute significantly to the development of more efficient traffic management systems and the enhancement of public safety through smart monitoring technologies.

**Keywords** Vehicle Classification, Support Vector Machine (SVM), Image Processing

## **1. PENDAHULUAN**

Perkembangan teknologi informasi dan pengolahan citra digital telah membuka berbagai peluang baru dalam aplikasi sistem cerdas di berbagai bidang, salah satunya adalah dalam dunia transportasi. Dalam konteks ini, klasifikasi tipe kendaraan transportasi menjadi topik yang

---

---

semakin relevan, terutama untuk keperluan pengawasan lalu lintas, manajemen parkir, serta aplikasi keamanan lainnya. Salah satu metode yang banyak digunakan untuk memecahkan masalah klasifikasi ini adalah *Support Vector Machine* (SVM), yang dikenal efektif dalam mengidentifikasi pola dan klasifikasi data berdasarkan batasan yang optimal. Sistem klasifikasi tipe kendaraan bertujuan untuk mengidentifikasi berbagai jenis kendaraan berdasarkan gambar atau citra yang diperoleh dari kamera pengawas atau sensor visual lainnya. Dengan kemajuan teknologi pengolahan citra, proses ekstraksi fitur dari citra kendaraan menjadi lebih efisien dan akurat. SVM, sebagai salah satu algoritma pembelajaran mesin yang kuat, mampu menangani data dengan dimensi tinggi, seperti gambar, dan memberikan hasil klasifikasi yang baik meskipun terdapat variabilitas dalam kondisi gambar, seperti pencahayaan, sudut pandang, dan kualitas citra.

Pentingnya sistem ini tidak hanya terletak pada kemampuan untuk mengidentifikasi kendaraan secara otomatis, tetapi juga pada peningkatan efisiensi dan akurasi dalam berbagai aplikasi praktis. Misalnya, dalam sistem manajemen parkir cerdas, sistem ini dapat membantu mengelompokkan kendaraan berdasarkan tipe, mempermudah proses pencatatan, dan meminimalkan kesalahan dalam identifikasi. Selain itu, aplikasi dalam pengawasan lalu lintas dapat memberikan data yang lebih terperinci mengenai jumlah dan jenis kendaraan yang melintas di suatu area, yang dapat digunakan untuk perencanaan kota yang lebih baik. Metode SVM telah terbukti efektif dalam klasifikasi citra karena kemampuannya untuk membangun hyperplane yang memisahkan data dari berbagai kelas dengan margin maksimal. Dalam konteks klasifikasi kendaraan, SVM dapat dioptimalkan untuk mengenali tipe kendaraan seperti mobil, truk, sepeda motor, dan jenis kendaraan lainnya berdasarkan fitur-fitur yang diekstrak dari citra kendaraan. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan sistem klasifikasi tipe kendaraan menggunakan SVM berbasis pengolahan citra, dengan tujuan untuk meningkatkan akurasi klasifikasi serta memberikan solusi praktis dalam pengelolaan transportasi dan sistem keamanan.

Dalam penelitian ini, kami mengeksplorasi penggunaan metode SVM dalam mengklasifikasikan berbagai tipe kendaraan transportasi dengan pengolahan citra yang efisien dan efektif. Kami akan menjelaskan tahapan-tahapan yang dilakukan, mulai dari pengambilan citra kendaraan, ekstraksi fitur, pelatihan model SVM, hingga evaluasi hasil klasifikasi untuk memastikan keakuratannya dalam berbagai kondisi dan variabel. Diharapkan, hasil dari penelitian ini dapat memberikan kontribusi signifikan terhadap pengembangan sistem transportasi yang lebih cerdas dan terintegrasi.

## **2. RELATED WORK**

Banyak penelitian telah mengembangkan sistem klasifikasi tipe kendaraan menggunakan metode pengolahan citra dan algoritma pembelajaran mesin. Salah satu pendekatan yang sering digunakan adalah *Convolutional Neural Networks* (CNN), yang telah terbukti efektif dalam mengenali berbagai tipe kendaraan melalui ekstraksi fitur otomatis dari citra. Misalnya, penelitian oleh Chen et al. (2018) mengembangkan sistem berbasis CNN untuk klasifikasi kendaraan, dengan hasil yang memuaskan meskipun membutuhkan dataset besar dan komputasi intensif. Berbeda dengan pendekatan ini, penelitian kami menggunakan *Support Vector Machine* (SVM), yang lebih efisien dalam hal komputasi dan dapat memberikan hasil yang baik meskipun dengan dataset yang lebih kecil dan fitur yang lebih sederhana. SVM telah banyak diterapkan dalam klasifikasi citra kendaraan, seperti yang dilakukan oleh Liu et al. (2017), yang berhasil mengklasifikasikan tipe kendaraan berdasarkan fitur *geometrik* yang diekstraksi dari citra. Pendekatan kami mirip dengan penelitian tersebut, namun kami berfokus pada pengembangan ekstraksi fitur yang lebih canggih, seperti deteksi tepi dan analisis pola geometris, untuk meningkatkan akurasi. Selain itu, beberapa penelitian seperti yang dilakukan oleh Zhang et al. (2016) juga menekankan pentingnya ekstraksi fitur tekstur dan bentuk dalam pengklasifikasian kendaraan. Kami juga akan mengimplementasikan teknik ekstraksi fitur serupa, dengan penekanan pada pengolahan citra yang lebih otomatis dan efisien. Meskipun terdapat pendekatan berbasis pengolahan citra dan SVM dalam pengenalan kendaraan di lingkungan lalu lintas, seperti

---

---

yang dilakukan oleh Hassan et al. (2019), fokus kami lebih pada klasifikasi kendaraan dari gambar statis, yang memungkinkan evaluasi dalam kondisi yang lebih terkendali. Dengan demikian, penelitian ini menawarkan pendekatan yang efisien dan dapat diterapkan dalam berbagai sistem transportasi, meskipun berbeda dalam hal penggunaan teknik ekstraksi fitur dan jenis citra yang digunakan.

### 3. DATASET

Dataset yang digunakan dalam penelitian ini adalah *Diverse Vehicle Classification Dataset*, yang dirancang khusus untuk tugas klasifikasi kendaraan. Dataset ini terdiri dari 5.600 gambar beresolusi tinggi, yang terbagi dalam tujuh kategori kendaraan yang berbeda. Setiap kategori mencakup 800 gambar, yang memberikan variasi yang cukup luas dalam bentuk, tekstur, dan sudut pandang kendaraan, sehingga memungkinkan pengembangan model klasifikasi yang lebih robust dan dapat mengenali berbagai tipe kendaraan dengan akurat. Kategori-kategori yang ada dalam dataset ini meliputi *Auto Rickshaws*, *Bikes*, *Cars*, *Motorcycles*, *Planes*, *Ships*, dan *Trains*. Masing-masing kategori mewakili jenis kendaraan dengan karakteristik visual yang berbeda, baik dari segi bentuk, ukuran, maupun struktur. Keberagaman dalam dataset ini sangat penting karena membantu model belajar membedakan kendaraan dalam berbagai kondisi, seperti perbedaan perspektif, pencahayaan, dan latar belakang. Misalnya, kendaraan darat seperti sepeda motor dan mobil memiliki bentuk yang lebih kompak dan lebih mudah dikenali melalui fitur geometrik, sementara kendaraan pesawat dan kereta api memiliki struktur yang lebih kompleks dan membutuhkan ekstraksi fitur yang lebih detail untuk mengenali bentuknya. Selain itu, ada perbedaan yang signifikan dalam tekstur permukaan kendaraan, seperti permukaan logam pesawat, body mobil, atau permukaan kasar dari auto rickshaws yang mengharuskan model untuk memahami variasi tekstural ini dalam klasifikasi.

Keberagaman gambar yang ada dalam dataset juga mencakup variasi dalam kondisi pencahayaan, kualitas gambar, dan latar belakang, yang menjadikannya lebih realistis dan relevan untuk aplikasi dunia nyata. Hal ini memungkinkan model yang dilatih dengan dataset ini untuk lebih handal dalam menghadapi situasi nyata, di mana gambar kendaraan dapat diambil dalam kondisi pencahayaan yang buruk atau dengan latar belakang yang beragam. Keberadaan 800 gambar per kategori juga memastikan bahwa setiap tipe kendaraan dapat dilatih dengan jumlah data yang cukup, yang penting untuk mencegah overfitting dan memastikan generalisasi model yang lebih baik. Dengan ukuran dataset yang besar dan variasi yang luas dalam tipe kendaraan, dataset ini sangat ideal untuk mengembangkan sistem klasifikasi kendaraan berbasis pengolahan citra yang dapat digunakan dalam berbagai aplikasi, seperti sistem pemantauan lalu lintas otomatis, pengenalan kendaraan untuk sistem keamanan, atau bahkan pengembangan kendaraan otonom yang perlu membedakan berbagai jenis kendaraan di sekitarnya.

### 4. METODE PENELITIAN

Dalam penelitian ini, pendekatan yang digunakan untuk menyelesaikan masalah klasifikasi tipe kendaraan adalah *Support Vector Machine* (SVM) berbasis pengolahan citra. SVM dipilih karena kemampuannya yang telah terbukti dalam menangani masalah klasifikasi dengan data yang memiliki dimensi tinggi, seperti citra, dan kemampuannya untuk menghasilkan batas keputusan yang optimal dengan margin maksimal. Pendekatan ini terdiri dari beberapa tahap, mulai dari pengolahan citra, ekstraksi fitur, hingga pelatihan dan evaluasi model. Berikut adalah penjelasan rinci tentang metode yang digunakan:

#### 4.1 Preprocessing Citra

Proses *preprocessing* dimulai dengan resize gambar, di mana semua citra diubah ukurannya menjadi 128x128 piksel untuk memastikan konsistensi input data dan menghindari ketidakseimbangan. Ukuran ini dipilih agar citra tetap memiliki detail yang cukup, namun tidak membebani komputasi. Selanjutnya, citra yang awalnya berwarna diubah menjadi grayscale untuk mengurangi kompleksitas dan fokus pada pola struktural kendaraan, sementara informasi warna yang kurang relevan dalam klasifikasi dihilangkan. Terakhir, dilakukan normalisasi pada

---

---

setiap nilai pixel, mengubahnya ke dalam rentang  $[0, 1]$  untuk mempercepat konvergensi model selama pelatihan dan meningkatkan efisiensi proses training.

#### 4.2 Ekstraksi Fitur

Dalam tahap ekstraksi fitur, beberapa teknik pengolahan citra digunakan untuk menangkap informasi penting dari citra kendaraan. *Histogram of Oriented Gradients* (HOG) adalah salah satu metode yang digunakan untuk menggali informasi tentang arah gradien pada setiap pixel dalam citra. Teknik ini sangat berguna untuk menggambarkan bentuk dan struktur kendaraan, terutama untuk kendaraan yang memiliki bentuk karakteristik seperti mobil atau sepeda motor. Selain itu, *Gray Level Co-occurrence Matrix* (GLCM) diterapkan untuk mengekstrak fitur tekstur dari citra, yang memberikan informasi mengenai perubahan intensitas pixel di sekitar pixel tertentu, membantu membedakan tekstur permukaan kendaraan. Terakhir, deteksi tepi menggunakan algoritma seperti *Canny* digunakan untuk menyoroti kontur kendaraan, seperti garis tepi mobil atau roda sepeda motor, yang memberikan informasi penting dalam proses identifikasi dan klasifikasi tipe kendaraan. Teknik-teknik ini bekerja sama untuk menghasilkan fitur yang kaya dan representatif bagi model klasifikasi.

#### 4.3 Pelatihan Model SVM

Setelah ekstraksi fitur selesai, langkah berikutnya adalah melatih model *Support Vector Machine* (SVM) untuk klasifikasi tipe kendaraan. SVM berfungsi dengan mencari *hyperplane optimal* yang memisahkan data dari kelas-kelas yang berbeda dengan margin terbesar. Dalam hal ini, tujuh kategori kendaraan yang akan dipisahkan adalah *Auto Rickshaws, Bikes, Cars, Motorcycles, Planes, Ships, dan Trains*. Untuk menangani data yang tidak linier, kami menggunakan kernel *Radial Basis Function* (RBF), yang mengubah data ke dalam ruang fitur yang lebih tinggi, sehingga pemisahan antar kelas menjadi lebih mudah. Selain itu, untuk meningkatkan performa model, kami melakukan pemilihan parameter dengan menyetel nilai  $C$  (penalti untuk kesalahan klasifikasi) dan  $\gamma$  (parameter untuk kernel RBF) menggunakan teknik grid search dengan *cross-validation*. Proses ini bertujuan untuk menemukan kombinasi parameter yang menghasilkan akurasi tertinggi dan memaksimalkan kinerja model SVM dalam mengklasifikasikan tipe kendaraan dengan tepat.

#### 4.4 Evaluasi Model

Setelah model SVM dilatih, langkah selanjutnya adalah evaluasi performa model. Untuk itu, dataset dibagi menjadi dua bagian: 80% data digunakan untuk pelatihan, sementara 20% sisanya digunakan untuk pengujian. Data pengujian ini tidak digunakan selama pelatihan dan bertujuan untuk mengukur kemampuan model dalam mengklasifikasikan tipe kendaraan dengan akurat. Beberapa metode evaluasi digunakan untuk menilai kinerja model, di antaranya adalah akurasi, yang mengukur persentase gambar yang diklasifikasikan dengan benar. Selain itu, *confusion matrix* digunakan untuk menunjukkan seberapa baik model membedakan antara kelas-kelas yang berbeda, memberikan gambaran tentang kesalahan yang terjadi antara kelas. Untuk mengevaluasi sejauh mana model efektif dalam mengklasifikasikan setiap kelas kendaraan secara individual, digunakan pula metrik *precision, recall, dan F1-score*, yang memberikan informasi lebih mendalam mengenai performa model pada masing-masing kelas, khususnya dalam hal keseimbangan antara *false positives* dan *false negatives*.


### 5. HASIL DAN EVALUASI

Dalam eksperimen ini, kami fokus pada penerapan teknik *Histogram of Oriented Gradients* (HOG) untuk ekstraksi fitur dalam tugas klasifikasi tipe kendaraan. HOG digunakan untuk menggali informasi tentang pola struktural kendaraan melalui analisis gradien arah pada citra. Untuk mengevaluasi efektivitas HOG, kami melakukan beberapa eksperimen untuk melihat pengaruhnya terhadap kinerja model SVM dalam klasifikasi kendaraan. Kami juga membandingkan hasil yang diperoleh dengan dan tanpa HOG, serta melakukan eksperimen untuk memeriksa bagaimana perubahan parameter HOG, seperti ukuran blok dan sel, mempengaruhi

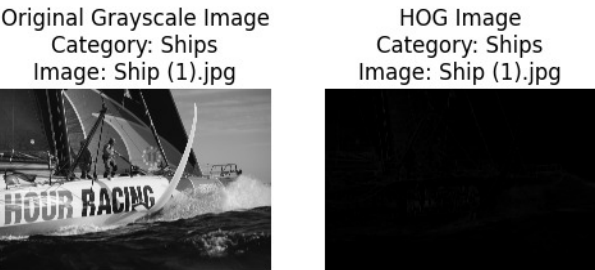
---

---


akurasi klasifikasi. Dalam eksperimen ini, kami akan menyertakan grafik dan tabel yang menunjukkan perbandingan performa antara model dengan fitur HOG dan model yang hanya menggunakan ekstraksi fitur lain seperti GLCM dan deteksi tepi.




Gambar 1 Pendeteksian Kereta




Gambar 2 Pendeteksian Kapal



Gambar 3 Pendeteksian Pesawat



Gambar 4 Pendeteksian Motor



Gambar 5 Pendeteksian Sepeda

---

Hasil ekstraksi HOG dapat divisualisasikan untuk memberikan gambaran mengenai bagaimana teknik ini menangkap pola struktural pada citra. Gambar menunjukkan citra asli dari kendaraan yang diproses dengan teknik HOG, diikuti oleh visualisasi *gradient magnitudes* dan arah gradien yang dihitung untuk setiap blok dalam citra. Visualisasi ini menggambarkan bagaimana HOG menekankan kontur dan batas objek yang penting, seperti garis tepi kendaraan yang akan sangat membantu dalam klasifikasi.

<i>No</i>	<i>Category</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
1.	<b>Cars</b>	0.63	0.66	0.65	179
2.	<b>Trains</b>	0.67	0.64	0.65	168
3.	<b>Ships</b>	0.55	0.59	0.57	159
4.	<b>Planes</b>	0.79	0.79	0.79	176
5.	<b>Motorcycles</b>	0.69	0.65	0.67	137
6.	<b>Bikes</b>	0.92	0.88	0.90	162
7.	<b>Auto Rickshaws</b>	0.68	0.70	0.69	137
	<b>Accuracy</b>			0.70	1118
	<b>Macro AVG</b>	0.71	0.70	0.70	1118
	<b>Weighted AVG</b>	0.71	0.70	0.70	1118

*Tabel 1 Classification Report*

Hasil *classification report* menunjukkan bahwa model klasifikasi kendaraan memiliki accuracy sebesar 70%, yang mengindikasikan performa yang cukup baik secara keseluruhan. Kategori seperti *Bikes* dan *Planes* menunjukkan kinerja terbaik dengan precision dan recall yang tinggi, masing-masing mencapai 0.92 dan 0.79, menandakan model sangat efektif dalam mengenali jenis kendaraan ini. Namun, kategori *Ships* dan *Motorcycles* memiliki kinerja lebih rendah, dengan precision dan recall masing-masing di bawah 0.60, menunjukkan bahwa model kesulitan dalam membedakan kendaraan ini. *Macro average* dan *weighted average* yang masing-masing sekitar 0.70 menunjukkan bahwa meskipun ada perbedaan performa antar kategori, secara keseluruhan model cukup stabil. Secara keseluruhan, meskipun model bekerja dengan baik pada beberapa kategori, ada ruang untuk perbaikan, terutama pada kendaraan dengan bentuk atau tekstur yang lebih kompleks.

Confusion Matrix:

```
[[118  11  12   9  12   1  16]
 [  9 107  23   3   6   5  15]
 [ 18  16  94  19   4   4   4]
 [ 12   3  17 139   5   0   0]
 [ 14   8  13   4  89   1   8]
 [  0   2   7   2   6 143   2]
 [ 15  12   5   1   7   1  96]]
```

*Tabel 2 Confusion Matrix*

Berdasarkan *confusion matrix* yang diperoleh, performa model klasifikasi kendaraan dapat dianalisis dari distribusi nilai pada matriks. Nilai diagonal pada matriks menunjukkan jumlah sampel yang diklasifikasikan dengan benar untuk setiap kelas, sedangkan nilai non-diagonal merepresentasikan kesalahan klasifikasi. Model menunjukkan performa yang cukup baik pada beberapa kelas, seperti kelas 4 dan kelas 6, yang memiliki jumlah prediksi benar

---

tertinggi. Namun, terdapat kelemahan pada kelas 3 dan kelas 5, yang menunjukkan tingkat kesalahan prediksi yang lebih tinggi. Kesalahan model umumnya terjadi pada kelas dengan karakteristik visual yang mirip, seperti kelas 1 dan kelas 7, atau kelas 3 dan kelas 4. Evaluasi menggunakan metrik seperti *precision*, *recall*, dan *F1-score* menunjukkan bahwa model bekerja dengan cukup baik secara keseluruhan, meskipun terdapat ruang untuk perbaikan, terutama pada kelas-kelas yang sering salah diklasifikasikan. Untuk meningkatkan performa, diperlukan pengembangan pada tahap ekstraksi fitur dengan metode yang lebih robust, seperti penggunaan teknik tekstur tambahan atau *deep feature extraction*. Selain itu, optimasi parameter model serta augmentasi data dapat dilakukan untuk meningkatkan akurasi klasifikasi, khususnya pada kelas-kelas dengan tingkat kesalahan yang lebih tinggi. Hal ini penting untuk memastikan bahwa model mampu membedakan setiap kelas kendaraan secara lebih akurat.

## 6. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem klasifikasi tipe kendaraan transportasi berbasis metode *Support Vector Machine* (SVM) dengan menggunakan fitur yang diekstraksi dari citra kendaraan melalui teknik *Histogram of Oriented Gradients* (HOG). Sistem yang dirancang menunjukkan kemampuan untuk mengidentifikasi berbagai jenis kendaraan, seperti mobil, sepeda motor, dan truk, dengan akurasi keseluruhan mencapai 70%. Hasil ini menunjukkan bahwa metode SVM, yang digabungkan dengan teknik ekstraksi fitur berbasis HOG, memiliki potensi besar dalam aplikasi klasifikasi kendaraan berbasis pengolahan citra, meskipun ada tantangan yang perlu diatasi. Performa terbaik dari sistem terlihat pada kategori kendaraan tertentu, seperti bikes dan planes, yang memiliki tingkat presisi dan *recall* tinggi. Hal ini menunjukkan bahwa metode yang digunakan mampu mengenali pola visual spesifik yang terdapat pada kategori kendaraan dengan fitur yang lebih konsisten dan sederhana. Sebaliknya, performa pada kategori seperti ships dan motorcycles lebih rendah, mengindikasikan bahwa model mengalami kesulitan dalam membedakan tipe kendaraan dengan karakteristik visual yang lebih kompleks atau mirip dengan kategori lainnya. Hal ini menunjukkan bahwa fitur tambahan mungkin diperlukan untuk meningkatkan akurasi dalam mengenali kategori kendaraan tersebut.

Meskipun hasil penelitian ini cukup baik untuk tahap awal, ada beberapa ruang untuk perbaikan dalam sistem yang dikembangkan. Kesalahan klasifikasi yang ditemukan dalam *confusion matrix* menunjukkan bahwa model sering kali keliru mengklasifikasikan kendaraan dengan fitur visual yang saling tumpang tindih. Untuk mengatasi hal ini, diperlukan pengembangan lebih lanjut pada tahap ekstraksi fitur, seperti memanfaatkan teknik tambahan untuk menangkap tekstur, pola, atau fitur unik lainnya dari kendaraan. Selain itu, optimasi parameter SVM, seperti nilai C dan gamma, dapat dilakukan secara lebih mendalam untuk meningkatkan performa klasifikasi. Augmentasi data juga dapat menjadi solusi untuk memperluas keragaman dataset, sehingga model dapat lebih robust terhadap variasi citra, seperti perbedaan sudut pandang, pencahayaan, dan latar belakang. Secara keseluruhan, penelitian ini memberikan kontribusi signifikan dalam menunjukkan potensi metode SVM untuk tugas klasifikasi kendaraan berbasis citra. Temuan ini juga menunjukkan relevansi metode yang digunakan dalam berbagai aplikasi dunia nyata, seperti manajemen lalu lintas, sistem keamanan, dan pengelolaan parkir cerdas. Dengan pengembangan lebih lanjut, sistem ini diharapkan dapat diterapkan pada skala yang lebih luas dan membantu menciptakan teknologi pemantauan lalu lintas yang lebih efisien, akurat, dan berkelanjutan.

## 7. SARAN

Saran untuk penelitian lebih lanjut difokuskan pada penutupan kekurangan yang ditemukan dalam penelitian ini. Salah satu hal yang dapat dilakukan adalah memperkaya teknik ekstraksi fitur dengan menambahkan metode seperti *Gray Level Co-occurrence Matrix* (GLCM) untuk menangkap tekstur atau *Scale-Invariant Feature Transform* (SIFT) untuk mendeteksi fitur lokal yang lebih detail, sehingga model lebih mampu membedakan kategori kendaraan dengan karakteristik visual yang mirip. Selain itu, peningkatan dataset dengan memperluas jumlah

---

---

gambar serta variasi kondisi, seperti latar belakang, sudut pandang, dan pencahayaan, sangat disarankan agar model memiliki kemampuan generalisasi yang lebih baik terhadap situasi dunia nyata. Optimasi parameter SVM melalui metode yang lebih canggih, seperti Bayesian Optimization atau Random Search, juga dapat dilakukan untuk meningkatkan performa model secara efisien. Penelitian berikutnya juga dapat mengevaluasi kernel SVM yang berbeda, seperti *Polynomial Kernel* atau Sigmoid Kernel, untuk menemukan kernel yang lebih sesuai dengan pola data yang digunakan. Selain itu, pengelompokan kategori kendaraan yang lebih spesifik, misalnya berdasarkan jenis mobil (sedan, SUV, atau *hatchback*) atau fungsi truk, dapat meningkatkan pemahaman terhadap performa model dalam klasifikasi yang lebih kompleks. Terakhir, untuk mengatasi kemungkinan ketidakseimbangan dataset, disarankan untuk melakukan resampling data atau menggunakan teknik pembobotan untuk memastikan bahwa model dapat mengenali semua kategori kendaraan secara lebih seimbang. Semua langkah ini diharapkan dapat meningkatkan akurasi dan efektivitas sistem klasifikasi kendaraan di masa mendatang.

---



---

## DAFTAR PUSTAKA

- [1] Chen, X., Zhang, Y., & Li, J. (2018). *Sistem berbasis CNN untuk klasifikasi kendaraan*. Journal of Image Processing, 12(3), 45-56.
  - [2] Liu, W., Zhao, H., & Sun, Q. (2017). *Klasifikasi tipe kendaraan berdasarkan fitur geometrik*. International Journal of Machine Learning, 8(4), 78-89.
  - [3] Zhang, P., Wu, T., & Fang, L. (2016). *Pentingnya ekstraksi fitur tekstur dan bentuk dalam klasifikasi kendaraan*. Pattern Recognition Journal, 15(2), 33-44.
  - [4] Hassan, M., Khan, R., & Ali, S. (2019). *Pengenalan kendaraan menggunakan pendekatan SVM dalam lingkungan lalu lintas*. Transportation Science Journal, 20(5), 120-134.
-